Базы данных

Лекция 11

Нереляционные БД: обзор, общее знакомство с Neo4j

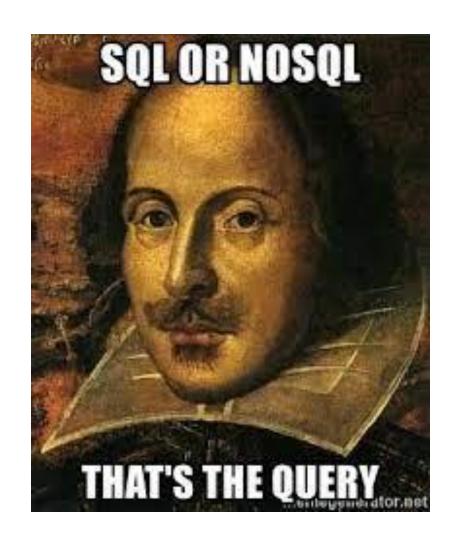
МФТИ, 2024 Игорь Шевченко

@igorshvch

I. Обзор NoSQL баз данных

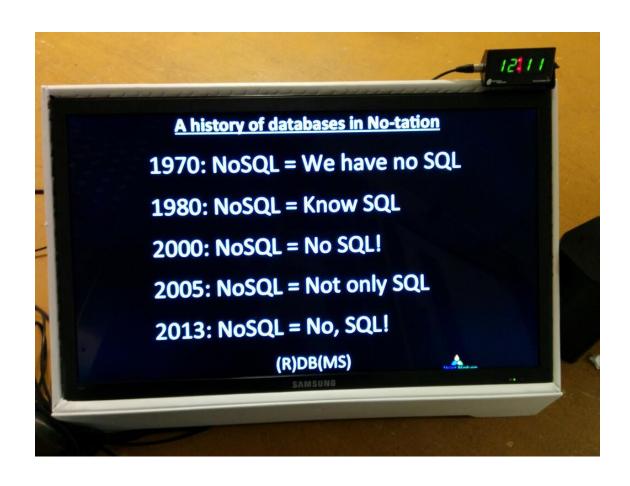
NoSQL: что это такое?

- SQL **язык** для реляционной модели данных
- NoSQL способ организации и управления данными, отличная от реляционной модели



Как появились NoSQL-БД и СУБД?

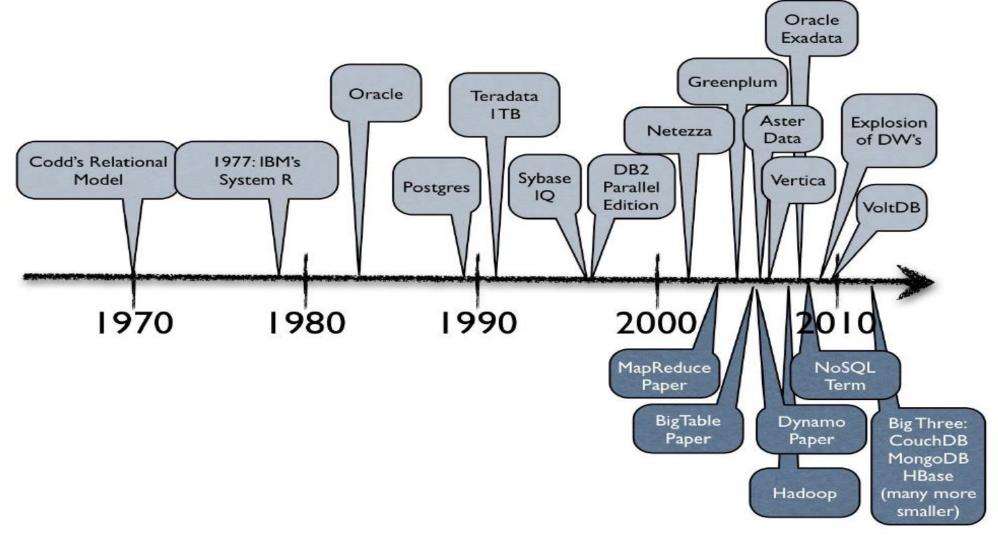
Фактически первые системы организации данных не отвечали положениям реляционной модели. NoSQL – это организация хранения и обработки данных, которая существует практически с первых серийных образцов компьютеров – ведь данные надо было как-то хранить!



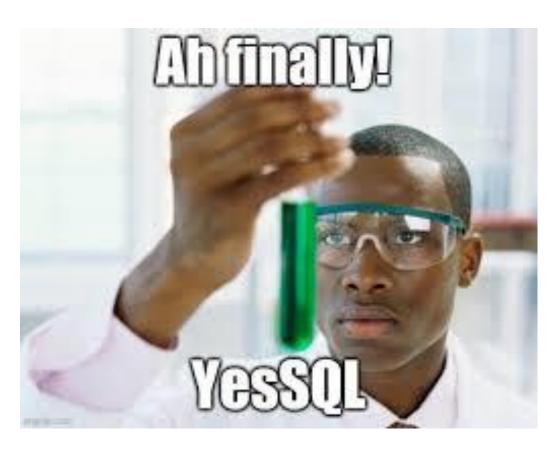
Небольшое отступление/экскурс в историю

- В самом начале мастер-файлы
- Дальше (1960-е) сетевые и иерархические базы данных:
 - статья инженеров GE Charles W Bachman, S. B. Williams «A general purpose programming system for random access memories» (1964/1965 г.), система менеджмента данных Integrated Data Store (IDS) (1963 г.)
 - статья инженера IBM William C. McGee «Generalized File Processing», (1969 г.), система управления данными Information Management System (IBM IMS)
 - Концептуальные наследники иерархических БД:
 - Файловые системы
 - XML
 - Сетевые БД «превратились» в графовые БД
- 1969 Эдгар Кодд издает для внутреннего пользования IBM "A Relational Model of Data for Large Shared Data Banks" (опубликована в 1970)

Небольшое отступление/экскурс в историю



Кстати: термин NoSQL



Термин 'NoSQL' появился в 1998 году. Его использовал разработчик Carlo Strozzi для своей легковесной СУБД, которая хотя и не использовала SQL, реализовывала реляционную модель.

Некоторые говорят, что сейчас вместо термина NoSQL правильнее было бы использовать термин NoREL

Тенденции развития моделей БД в 1990

• BigData – большие объемы данных, масштабируемость

• Web — обеспечение доступности данных для любых ресурсов

• Agile – быстрота разработки (MVP делают за 3-4 месяца)

Принципы работы РБД: ACID

- Atomicity Атомарность
- Consistency Согласованность
- Isolation Изолированность
- Durability Надежность

IBM Information Management System (СУБД) начала поддерживать ACID с 1973 года

Обобщение: теорема САР (Брюера)

Согласно теореме, есть три основных свойства, характеризующих любую БД (СУБД):

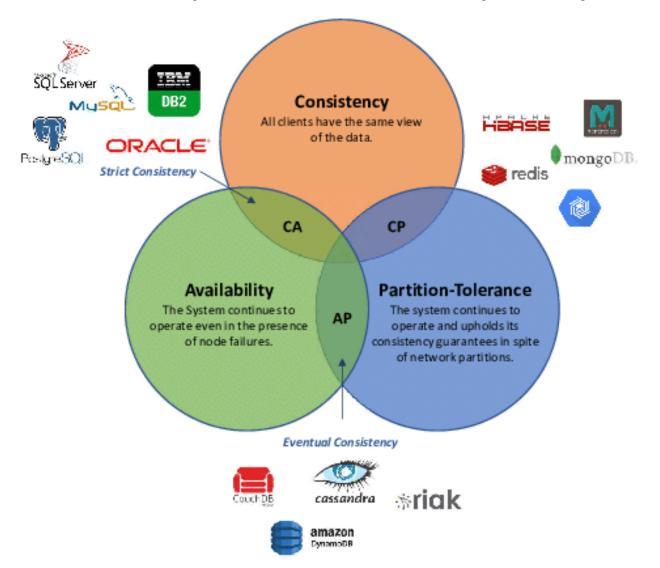
- Consistency (согласованность данных)
- Availability (доступность)
- Partition tolerance (устойчивость к разделению)
- и максимизировать мы можем <u>не более двух из них</u>

<u>Применение</u>:

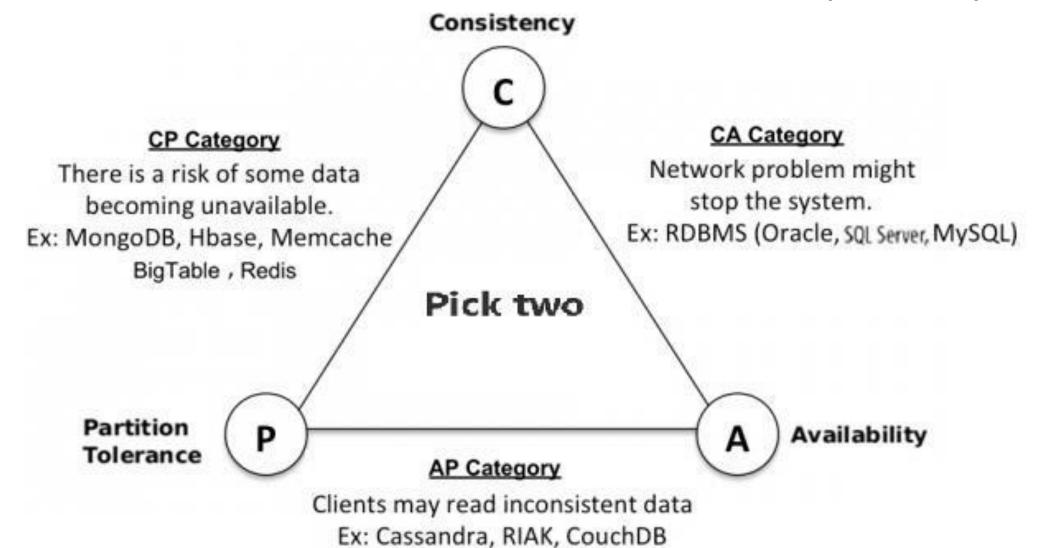
позволяет классифицировать все модели БД по парам указанных свойств.

Предложена Э. Брюером в ~2000 году

Обобщение: теорема САР (Брюера)



САР: недостатки максимизации параметров



Альтернатива ACID - BASE

• Модель BASE появилась как «следствие» CAP-теоремы. Ей «руководствуются» при проектирование NoSQL-СУБД и противопоставляют ее ACID

• BASE:

- Basically Available (базовая доступность)
 - Гарантирован ответ на каждый запрос к данным
- Soft State (неустойчивое состояние)
 - Данные могут меняться в отсутствие операций ввода
- Eventual Consistency (согласованность в конечном счете)
 - В конечном итоге (при прекращении операций ввода) изменения в данных будут прокинуты во все узлы БД

NoSQL: классификация

Существует множество категорий NoSQL-систем, например:

- Key-Value Stores
- Column-oriented DBMS
- Document Stores
- Graph DBMS
- RDF Stores (данные представлены в тройках: субъект-предикат-объект)
- Native XML DBMS
- Content Stores (хранение контента целиком, включая мета-данные)
- Search Engines (поисковые движки, напр., Elasticsearch)

NoSQL: классификация

В качестве основных видов NoSQL моделей рассматривают четыре следующих:

- 1) Graph DB
- 2) Document DB
- 3) Key-Value Stores
- 4) Column-oriented DB (частный случай Wide-column DB)

- рассмотрим подробнее каждый из указанных видов

Отличия Column-oriented от Wide-column

• Column-oriented базы данных:

- основное назначение: оптимизированы для операций агрегации и аналитических запросов, которые читают большие объемы данных из определенных столбцов по всей таблице.
- хранение данных: данные хранятся по столбцам, что позволяет выполнять быстрые агрегации и сжатие данных, так как столбцы содержат данные одного типа.
- примеры: Apache ClickHouse, Vertica, SAP HANA.

• Wide-column базы данных:

- основное назначение: предназначены для масштабируемости и гибкости в приложениях, требующих обработки больших объемов данных с различной структурой.
- хранение данных: данные организованы в таблицах, где каждая строка может иметь различное количество столбцов и структуру. Столбцы группируются в семейства столбцов, которые хранятся вместе, что улучшает производительность чтения и записи.
- примеры: Apache Cassandra, Google Bigtable, Apache HBase.

Отличия Column-oriented от Wide-column

- Структура хранения: В column-oriented базах данных структура фиксирована и однородна, каждая запись или строка содержит данные для каждого столбца. В wide-column базах данных каждая строка может иметь различный набор столбцов, что придает дополнительную гибкость в управлении данными.
- Семейства столбцов: Wide-column базы данных используют понятие семейств столбцов, где столбцы, логически связанные между собой, хранятся вместе. Это отличает их от column-oriented баз данных, где столбцы обычно не группируются таким образом.

NoSQL: Key-Value Stores / обзор

	Rank				Score		
Apr 2024	Mar 2024	Apr 2023	DBMS	Database Model	Apr 2024	Mar 2024	Apr 2023
1.	1.	1.	Redis 🞛	Key-value, Multi-model 👔	156.44	-0.56	-17.11
2.	2.	2.	Amazon DynamoDB 🖽	Multi-model 🛐	77.57	-0.15	+0.12
3.	3.	3.	Microsoft Azure Cosmos DB 🖽	Multi-model 🛐	29.85	-0.54	-5.23
4.	4.	4.	Memcached	Key-value	20.74	-0.07	-1.25
5.	1 6.	5.	etcd	Key-value	7.64	-0.02	-0.99
6.	4 5.	6.	Hazelcast	Key-value, Multi-model 🛐	6.87	-0.79	-0.89
7.	7.	7.	Aerospike 🔡	Multi-model 🛐	6.10	-0.41	-0.30
8.	8.	8.	Ehcache	Key-value	5.23	-0.32	-0.91
9.	9.	1 0.	Riak KV	Key-value	4.44	-0.51	-0.75
10.	1 4.	1 20.	InterSystems IRIS 🖽	Multi-model 👔	4.39	+0.57	+1.19

По данные ресурса <u>DB-Engines</u> от австрийской консалтинговой компании Solid IT

NoSQL: Key-Value Stores / Характеристики

Плюсы:

- Наиболее простой вид из прочих. Принцип работы аналогичен ассоциативному массиву на хэш-таблицах
- Отсутствует какая-либо схема данных, value может быть любой объект, в качестве ключа может выступать не единичное значение, а массив

Минусы:

- За счет необходимости просмотра всей хэш-таблицы при чтении может не очень хорошо масштабироваться
- Подходят только для очень простых данных реализовать связи за счет самой модели невозможно
- Сложности с построением сложных запросов

NoSQL: Wide-column DB / Обзор

Rank					Score		
Apr 2024	Mar 2024	Apr 2023	DBMS	Database Model	Apr Mar 2024 2024	Apr 2023	
1.	1.	1.	Cassandra 🔠	Wide column, Multi-model 👔	103.86 -0.72	-7.94	
2.	2.	2.	HBase	Wide column	31.25 -0.35	-6.55	
3.	3.	3.	Microsoft Azure Cosmos DB 🖽	Multi-model 👔	29.85 -0.54	-5.23	
4.	4.	4.	Datastax Enterprise 🚹	Wide column, Multi-model 🛐	6.31 -0.76	-0.48	
5.	5.	5.	ScyllaDB 🔡	Wide column, Multi-model 🛐	5.27 -0.42	-0.58	
6.	6.	6.	Microsoft Azure Table Storage	Wide column	4.92 -0.43	-0.76	
7.	1 8.	7.	Accumulo	Wide column	3.61 -0.17	-1.57	
8.	4 7.	8.	Google Cloud Bigtable	Multi-model 👔	3.58 -0.29	-1.34	
9.	1 0.	1 0.	Amazon Keyspaces	Wide column	0.92 +0.06	+0.18	
10.	4 9.	4 9.	HPE Ezmeral Data Fabric	Multi-model 👔	0.89 -0.16	-0.33	

NoSQL: Wide-column DB / Характеристики

Плюсы:

- Гибкость в физическом хранении данных строки таблиц распределяются по разным серверам, в строке могут быть колонки разных типов данных
- Быстрота обработки запросов, связанных с извлечением данных из колонки
- Хорошее сжатие (за счет сериализации колонок, т.е. массивов, хранящих однотипные данные)

Минусы:

- Долгая (в сравнении с РСУБД) обработка запросов, извлекающих строки целиком. Долгая обработка JOIN-запросов и т.п. где требуется построчное считывание
- Долгая (в сравнении с РСУБД) запись данных в строку
- (почти полная) невозможность создания композитных индексов

NoSQL: Document DB / Обзор

Apr 2024	Rank Mar 2024	Apr	DBMS	Database Model	S Apr 2024	core Mar 2024	Apr 2023
1.	1.	1.	MongoDB 🚻	Document, Multi-model 👔	423.96	-0.57	-17.93
2.	2.	2.	Amazon DynamoDB 🚹	Multi-model 👔	77.57	-0.15	+0.12
3.	3.	3.	Databricks 🖽	Multi-model 👔	76.33	+1.99	+15.36
4.	4.	4.	Microsoft Azure Cosmos DB 🚼	Multi-model 👔	29.85	-0.54	-5.23
5.	5.	5.	Couchbase 🔠	Document, Multi-model 👔	18.46	-0.69	-5.30
6.	6.	6.	Firebase Realtime Database	Document	15.00	-0.07	-3.22
7.	7.	7.	CouchDB	Document, Multi-model 👔	10.26	-1.47	-4.36
8.	8.	8.	Google Cloud Firestore	Document	8.96	-1.01	-2.13
9.	9.	1 0.	Realm	Document	7.71	+0.01	-0.57
10.	10.	4 9.	MarkLogic	Multi-model 👔	6.50	-0.57	-1.84

NoSQL: Document DB / Характеристики

Плюсы:

- Нет поддержки схемы данных
- Удобный формат (MongoDB JSON, один из стандартов для web)
- Быстрые запись/чтение
- Удобные репликация и шардирование

Минусы:

- Нет поддержки схемы данных!!!
- Плохая поддержка сложных SQL-подобных запросов

NoSQL: Graph DB / Обзор

	Rank				Score		
Apr 2024	Mar 2024	Apr 2023	DBMS	Database Model	Apr Mar Apr 2024 2024 2023		
1.	1.	1.	Neo4j 🔠	Graph	44.47 +0.11 -7.13		
2.	2.	2.	Microsoft Azure Cosmos DB 🚹	Multi-model 👔	29.85 -0.54 -5.23		
3.	3.	3.	Aerospike 🔡	Multi-model 🔟	6.10 -0.41 -0.30		
4.	4.	4.	Virtuoso 🞛	Multi-model 📆	4.20 -0.19 -2.04		
5.	5.	5.	ArangoDB 🚻	Multi-model 📆	3.77 -0.45 -1.03		
6.	6.	6.	OrientDB	Multi-model 📆	3.27 -0.11 -0.79		
7.	1 8.	1 9.	GraphDB 🔠	Multi-model 🔟	3.10 +0.19 +0.76		
8.	4 7.	1 11.	Memgraph 🔡	Graph	3.00 -0.09 +0.88		
9.	9.	4 7.	Amazon Neptune	Multi-model 🔟	2.58 -0.24 -0.11		
10.	10.	10.	NebulaGraph 🔡	Graph	2.12 -0.24 -0.05		

NoSQL: Graph DB / Характеристики

Плюсы:

- В основе проработанная математическая модель
- Удобно строить специфические модели предметной области базы знаний
- Удобное расширение модели данных
- Быстрота обработки запросов за счет специфики модели данных

Минусы:

- Разнородные языки запросов нет стандарта по отрасли
- Не поддерживают абстракцию транзакций
- Сложно обсчитывать запросы с агрегированием

SQL vs NoSQL: реальное положение дел

Rank					Score		
Apr 2024	Mar 2024			Apr 2024	Mar 2024	Apr 2023	
1.	1.	1.	Oracle 🚹	Relational, Multi-model 🔞	1234.27	+13.21	+5.99
2.	2.	2.	MySQL 🚹	Relational, Multi-model 🔞	1087.72	-13.77	-70.06
3.	3.	3.	Microsoft SQL Server 🚹	Relational, Multi-model 🛐	829.80	-16.01	-88.73
4.	4.	4.	PostgreSQL 🔠	Relational, Multi-model 🛐	645.05	+10.15	+36.64
5.	5.	5.	MongoDB 🚹	Document, Multi-model 👔	423.96	-0.57	-17.93
6.	6.	6.	Redis 🚹	Key-value, Multi-model 🛐	156.44	-0.56	-17.11
7.	7.	1 8.	Elasticsearch	Search engine, Multi-model 🛐	134.78	-0.01	-6.29
8.	8.	4 7.	IBM Db2	Relational, Multi-model 🛐	127.49	-0.26	-18.00
9.	9.	1 2.	Snowflake 😷	Relational	123.20	-2.18	+12.07
10.	10.	4 9.	SQLite #	Relational	116.01	-2.15	-18.53

NoSQL: достоинства

- Позволяют хранить большие объемы слабоструктурированной информации в более-менее связном виде
- Удобство масштабирования (в сравнении с РБД и РСУБД)
- Удобство репликации и шардирования
- Быстрота разработки

NoSQL: недостатки

- Не требуется проектирование схемы предметной области
- Поощряют накопление несогласованной информации в БД
- Для сложных предметных областей: схема данных стремится к реляционной. При этом преимущества реляционной модели остаются недоступными
- Согласованность в конечном счёте и BASE-принцип вносят риски ошибок

И на последок... Векторные базы данных

- По сути своей это не какой-то новый тип баз данных, а нечто вроде надстройки над уже существующими системами хранения. В качестве «backend'a» в таких БД могут использоваться key-value БД
- Цель оптимизировать хранение и обработку vector embeddings
- Концептуально включают в себя три части: data store, vector indexing mechanism, query mechanism
- Индексация и запросы обрабатываются с использованием специальных библиотек, не относящихся к технологии баз данных. Стандартный вариант FAISS (Facebook AI Similarity Search). Важное отличие от результатов запроса в иных типах БД корректность результата носит *вероятностный* характер

Векторные базы данных: примеры

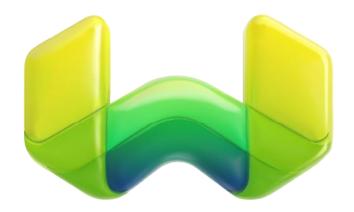
Milvus



• Pincone



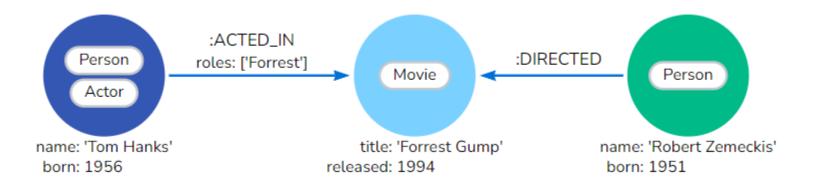
Weaviate



II. Общее знакомство с Neo4j

Neo4j: модель данных

- Данные и отношения между ними представлены в виде 3 объектов модели:
 - узлов (nodes)
 - отношений (relationships)
 - свойств (properties).



Neo4j: Nodes

- Узлы представляют сущности или объекты в графе. Они похожи на записи или объекты в традиционной базе данных.
- Каждый узел может иметь одну или несколько меток, которые определяют его роль или тип в графе.
- Метки помогают эффективно организовывать и запрашивать данные.
- Узлы могут иметь свойства, которые представляют собой пары ключзначение, предоставляющие дополнительную информацию об узле. Свойства могут быть проиндексированы для более быстрого поиска.
- Узлы могут иметь метки (labels)
- Пример синтаксиса создания узла:

```
CREATE (:Person:Actor {name: 'Tom Hanks', born: 1956})
```

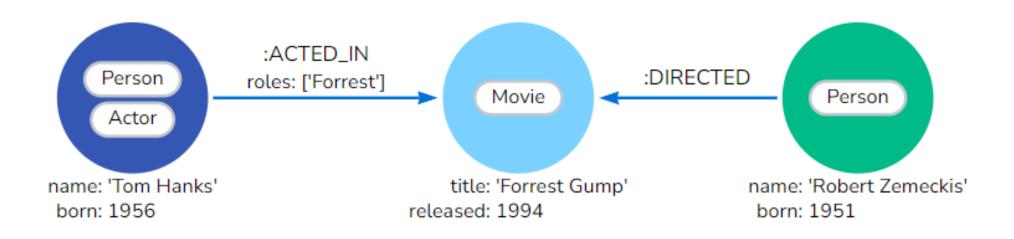
Neo4j: Properties

- Свойства это пары ключ-значение, которые используются для хранения данных об узлах и отношениях.
- Значение свойства может:
 - содержать различные типы данных, такие как число, строка или булево значение.
 - содержать список (массив), состоящий, например, из строк, чисел или булевых значения (компоненты должны принадлежать к одному типу).
- Пример свойств со значениями разных типов:

Neo4j: Relationships

- Отношение описывает, как связаны между собой исходный узел и целевой узел. Узел может иметь связь с самим собой.
- Отношения всегда направлены и имеют начальный узел и конечный узел. Они представляют собой отношения между двумя узлами и могут иметь определенный тип или метку (label).
- Как и узлы, отношения могут иметь свойства (properties), которые предоставляют дополнительную информацию об отношениях.
- Синтаксис создания отношения:

Neo4j: пример создания элементарной БД



```
CREATE (:Person:Actor {name: 'Tom Hanks', born:
1956})-[:ACTED_IN {roles: ['Forrest']}]->(:Movie
{title: 'Forrest Gump'})<-[:DIRECTED]-(:Person
{name: 'Robert Zemeckis', born: 1951})</pre>
```

Neo4j: некоторые аспекты языка CQL (Cypher Query Language)

- Используются ключевые слова, похожие на SQL: MATCH, WHERE, CREATE, DELETE, RETURN и дргие
- Пример pattern matching:

```
MATCH (me)-[:KNOWS*1..2]-(remote_friend)
WHERE me.name = 'Filipa'
RETURN remote_friend.name
```

- Допустимо использовать агрегирующие функции, например: COUNT, SUM, MIN, MAX
- Допустимо использовать стандартные операторы сравнения и логические операторы: >, <, =, AND, OR, NOT:

```
MATCH (node:Label)
WHERE node.property > 10 RETURN node
ORDER BY node.property
```

- Помимо CREATE для определения данных используются такие конструкции, как SET, DELETE, MERGE. Пример использования MERGE:
 - MERGE (m:Movie {title: 'The Matrix', year: 1999})
 - Используется для исключения дублирования данных (в примере выше узел не будет создан, если в БД уже есть узел с аналогичными свойствами)

Neo4j: дополнительные возможности

• Допускается создание индексов:

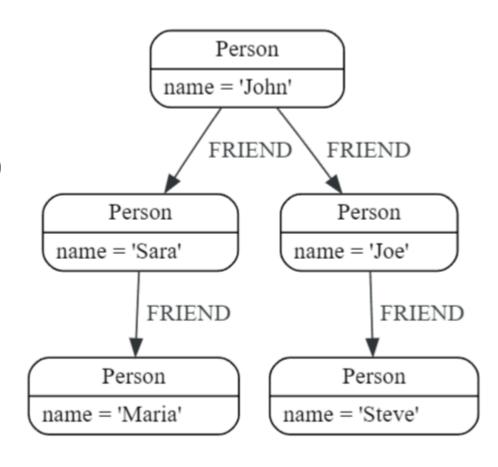
• Допускается наложение ограничений на

```
CREATE CONSTRAINT constraint_example_1 FOR
(movie:Movie) REQUIRE movie.title IS UNIQUE
```

• Допускается создание пользовательских функций

Neo4j: пример работы с запросами

```
MATCH (john:Person {name: 'John'})
MATCH (john)-[:FRIEND]->(friend)
RETURN friend.name AS friendName
```



Как отработает запрос из предыдущего примера

MATCH (john:Person {name: 'John'})	john ({name: 'John'})	
MATCH (john)-[:FRIEND]->(friend)	john	friend
	({name: 'John'})	({name: 'Sara'})
	({name: 'John'})	({name: 'Joe'})
RETURN friend.name AS friendName		
RETORN TITETION AO TITETIONALE	friendName	
	'Sara'	
	'Joe'	

Еще пример запроса

MATCH (j:Person)

```
WHERE j.name STARTS WITH "J«
CREATE (j)-[:FRIEND]->(jj:Person {name: "Jay-jay"})

- запрос находит все узлы, у которых свойство name начинается с "J", и для каждого такого узла создает другой узел со свойством name, установленным в "Jay-jay".
```

Clause	Table of intermediat	e results after the clause	State of the graph after the clause, changes in red
MATCH (j:Person) WHERE j.name STARTS WITH "J"	j ({name: 'John'}) ({name: 'Joe'})		Person name = 'John' Person name = 'Sara' Person name = 'Joe' FRIEND Person name = 'Maria' Person name = 'Steve'
<pre>CREATE (j)-[:FRIEND]-> (jj:Person {name: "Jay- jay"})</pre>	j ({name: 'John'}) ({name: 'Joe'})	jj ({name: 'Jay-jay'}) ({name: 'Jay-jay'})	Person name = 'John' FRIEND FRIEND Person name = 'Sara' Person name = 'Joe' FRIEND FRIEND Person name = 'Jay-jay' Person name = 'Maria' Person name = 'Steve' Person name = 'Jay-jay'

• Рекомендации по интерпретации реляционных данных в графовые с из официального руководства Neo4j (<u>Tutorial: Import Relational Data Into Neo4j - Developer Guides</u>):

When deriving a graph model from a relational model, you should keep a couple of general guidelines in mind.

- 1. A row is a node.
- 2. A table name is a label name.
- 3. A join or foreign key is a relationship.

Что почитать?

• Официальная документация:

https://neo4j.com/docs/

• Google...